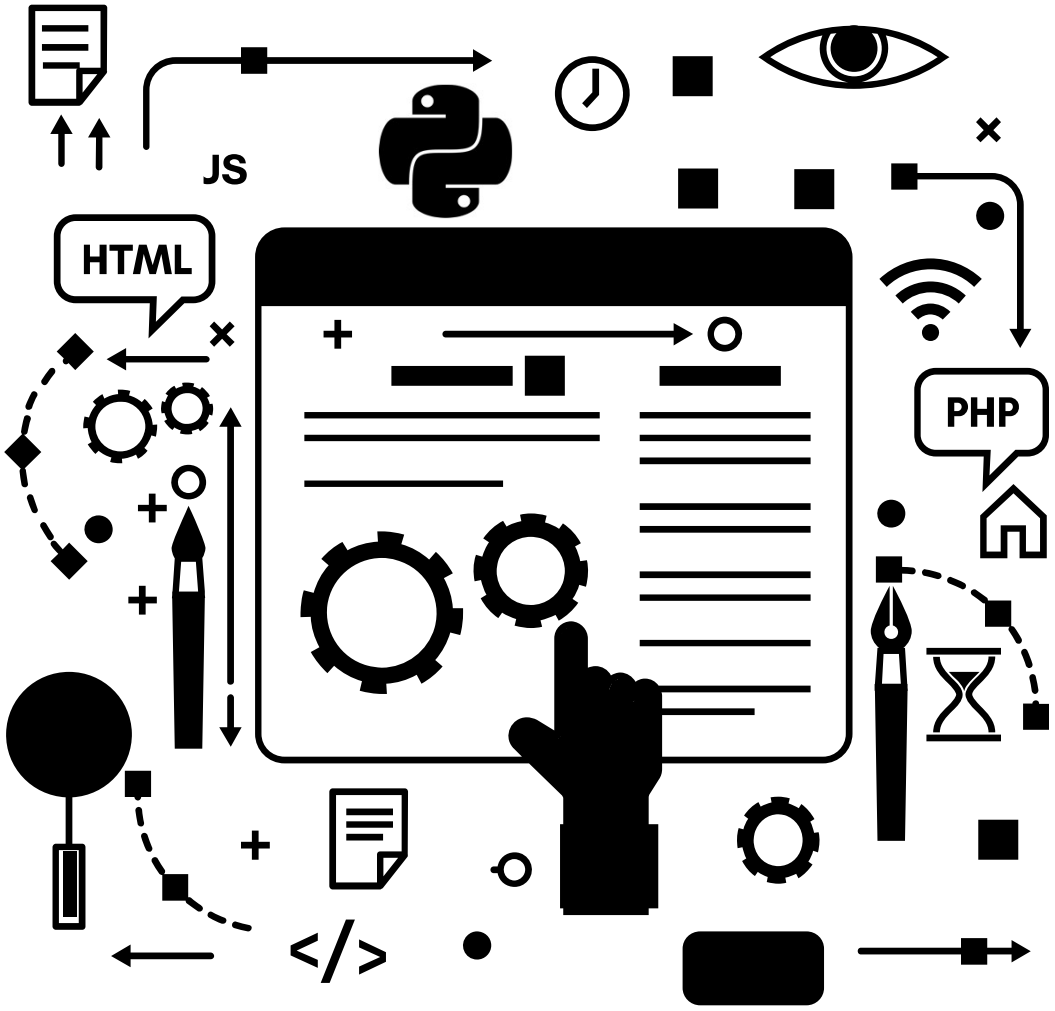


ANALISIS EXPLORATORIO

Mg. Bryan Fernandez Ebrath

Practica

Consultar la diferencia entre variables categóricas y continuas.

Nota: una variable categoría puede contener números.

Practica

Base de datos ROTACION

Brinda la información relacionada de empleados que hicieron o no cambio de entidad laboral. Tiene 24 columas entre las cuales se destaca

- Edad
- Departamento en el que se desempeña
- Viaja de negocios
- Distancia de casa
- Estado civil
- Ingreso mensual
- Años
- Genero.

Cargar el archivo

Cargar el archivo de bd

```
import pandas as pd
import numpy as np
from matplotlib import pyplot as plt
original_df = pd.read_excel('Datos_Rotacion.xlsx')
original_df
```

Verificar que el cargue fue exitoso

Practica

Información de las columnas

- original_df.info( )

```
Data columns (total 24 columns):
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   Rotación                      1470 non-null   object
 1   Edad                          1470 non-null   int64
 2   Viaje de Negocios             1470 non-null   object
 3   Departamento                  1470 non-null   object
 4   Distancia_Casa                1470 non-null   int64
 5   Educación                     1470 non-null   int64
 6   Campo_Educación               1470 non-null   object
 7   Satisfacción_Ambiental        1470 non-null   int64
 8   Genero                        1470 non-null   object
 9   Cargo                         1470 non-null   object
 10  Satisfación_Laboral           1470 non-null   int64
 11  Estado_Civil                  1470 non-null   object
 12  Ingreso_Mensual               1470 non-null   int64
 13  Trabajos_Anteriores           1470 non-null   int64
 14  Horas_Extra                   1470 non-null   object
 15  Porcentaje_aumento_salarial   1470 non-null   int64
 16  Rendimiento_Laboral           1470 non-null   int64
 17  Años_Experiencia              1470 non-null   int64
 18  Capacitaciones                1470 non-null   int64
 19  Equilibrio_Trabajo_Vida       1470 non-null   int64
 20  Antigüedad                    1470 non-null   int64
 21  Antigüedad_Cargo              1470 non-null   int64
 22  Años_ultima_promoción         1470 non-null   int64
 23  Años_acargo_con_mismo_jefe    1470 non-null   int64
dtypes: int64(16), object(8)
memory usage: 275.8+ KB
```

Frecuencias absoluta y relativa

Los datos de una variables aparecen organizados en una tabla de frecuencias

FRECUENCIA ABSOLUTA

Frecuencia absoluta de un valor es el número de veces que se repite.

CALIFICACIONES	FRECUENCIA
INSUFICIENTE	2
SUFICIENTE	10
BIEN	6
NOTABLE	3
SOBRESALIENTE	2
TOTAL	23

La frecuencia absoluta de la calificación BIEN es 6

$$f(\text{BIEN}) = 6$$

FRECUENCIA RELATIVA

Frecuencia relativa es el cociente entre el número de veces que se repite.

CALIFICACIONES	FRECUENCIA	FRECUENCIA RELATIVA
BIEN	6	$\frac{6}{23}$

$$\text{Frecuencia relativa (BIEN)} = \frac{\text{6 veces se repite el dato}}{\text{23 datos en total}}$$

La frecuencia relativa de la calificación BIEN es de 6/23

$$f_r(\text{BIEN}) = \frac{6}{23}$$

Frecuencia absoluta

Para saber cuantos registros hay de cada categoría

```
f_absoluta=pd.value_counts(original_df['Departamento'])
f_absoluta
```

La frecuencia absoluta es una medida estadística que nos da información acerca de la cantidad de veces que se repite un suceso

Permite indicar cuantas registros hay de las categoría IyD,Ventas y RH

```
IyD        961
Ventas     446
RH          63
Name: Departamento, dtype: int64
```

Practica

Aplicar la frecuencia absoluta a todas las variables **categóricas** de la fuente de datos.

Frecuencia relativa

F_relativa

```
f_relativa = 100 * original_df['Departamento'].value_counts() / len(original_df['Departamento'])
f_relativa
```

La frecuencia relativa es una medida estadística que se calcula como el cociente de la frecuencia absoluta de algún valor de la población/muestra (fi) entre el total de valores que componen la población/muestra (N).

```
IyD       65.374150
Ventas    30.340136
RH         4.285714
Name: Departamento, dtype: float64
```

Practica

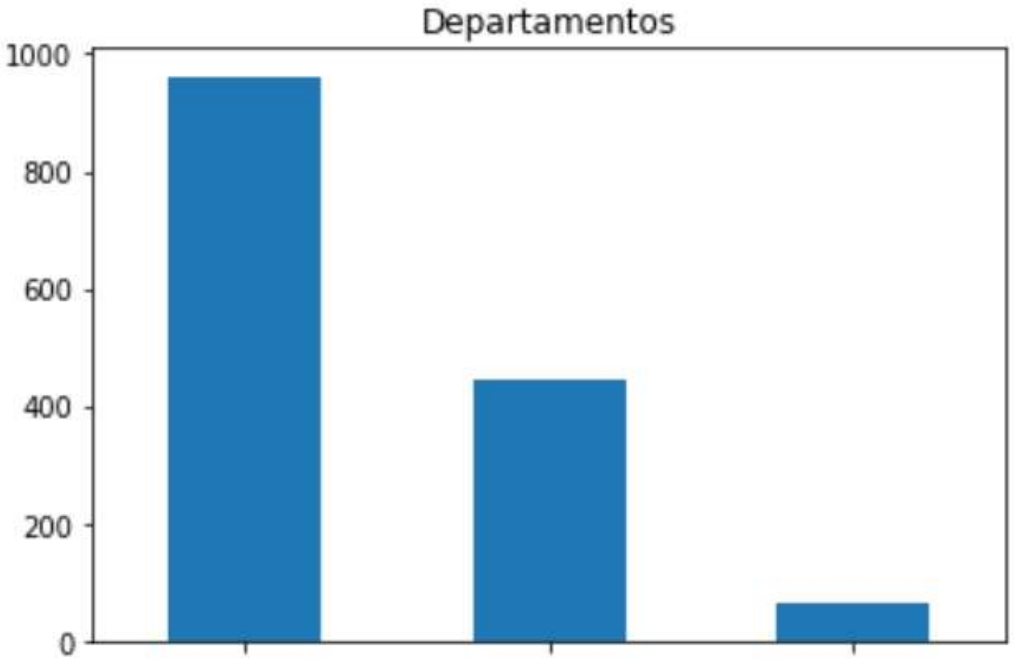
Aplicar la frecuencia relativa a todas las variables **categóricas** de la fuente de datos.



Practica

Grafico de la de frecuencia absoluta de una variable categoría

```
grafico_1 = original_df['Departamento'].value_counts().plot(kind='bar',title='Departamentos')
grafico_1
```



Practica

Grafico de la de frecuencia relativa de una variable categoría

```
grafico_2=plot = (100 * original_df['Departamento'].value_counts() / len(original_df['Departamento'])).plot(kind='bar', title='% departamentos')
grafico_2
```

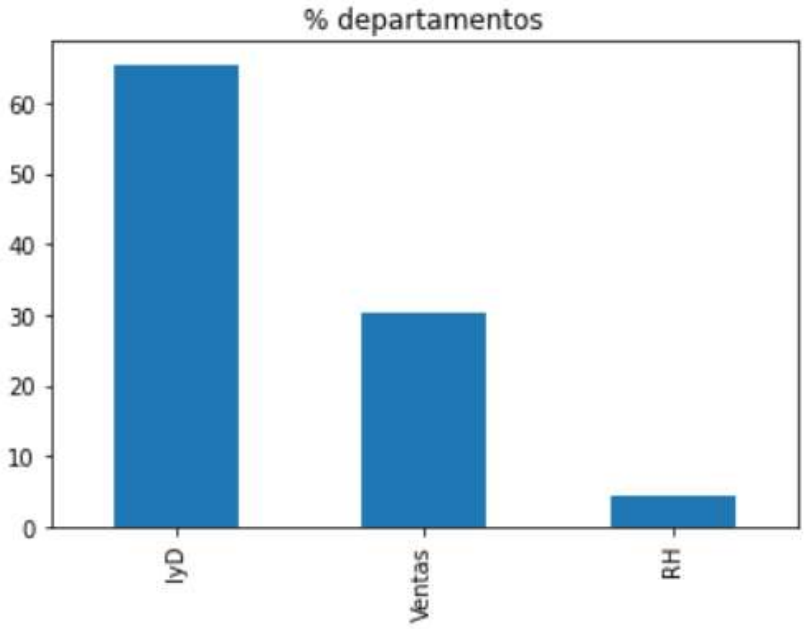
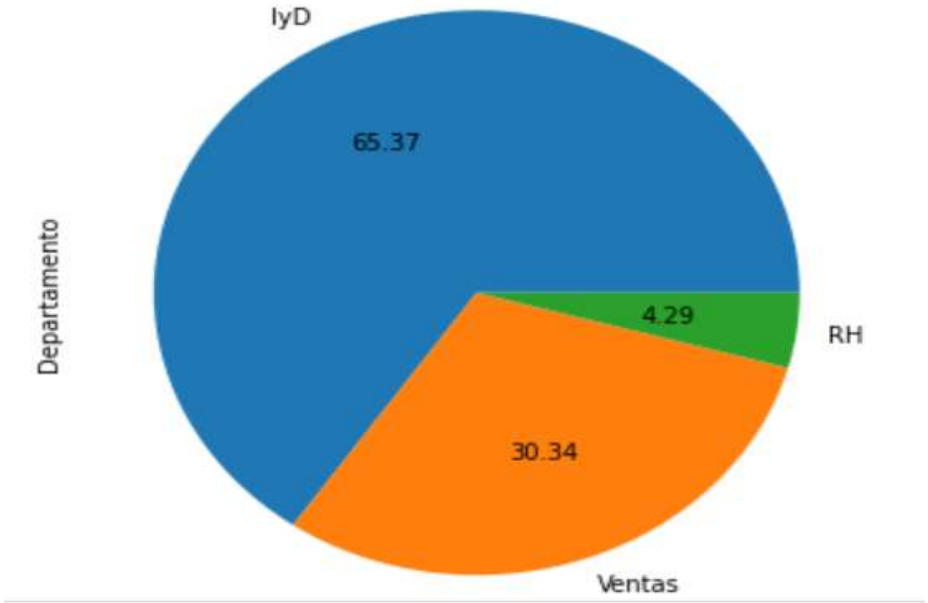


Gráfico circular

```
grafico_3 = original_df['Departamento'].value_counts().plot(kind='pie', autopct='%.2f', figsize=(6, 6),title='departamentos')
grafico_3
```



Practica

Una tabla de contingencia es una herramienta utilizada en la rama de la estadística, la cual consiste en crear al menos dos filas y dos columnas para representar datos categóricos en términos de conteos de frecuencia.

Ejemplo

	Bajo	Medio	Alto	Total
A	14	22	38	**74**
B	10	11	49	**70**
C	6	11	48	**65**
Total	**30**	**44**	**135**	**209**

Practica

Tabla de contingencia de **departamento** Vs **estado civil**

```
departamento_vs_estadocivil=pd.crosstab(index=original_df['Departamento'],columns=original_df['Estado_Civil'], margins=True)
departamento_vs_estadocivil
```

Estado_Civil	Casado	Divorciado	Soltero	All
Departamento				
IyD	433	224	304	961
RH	34	16	13	63
Ventas	206	87	153	446
All	673	327	470	1470

Practica

Tabla de contingencia de **departamento** Vs **Campo_Educación**

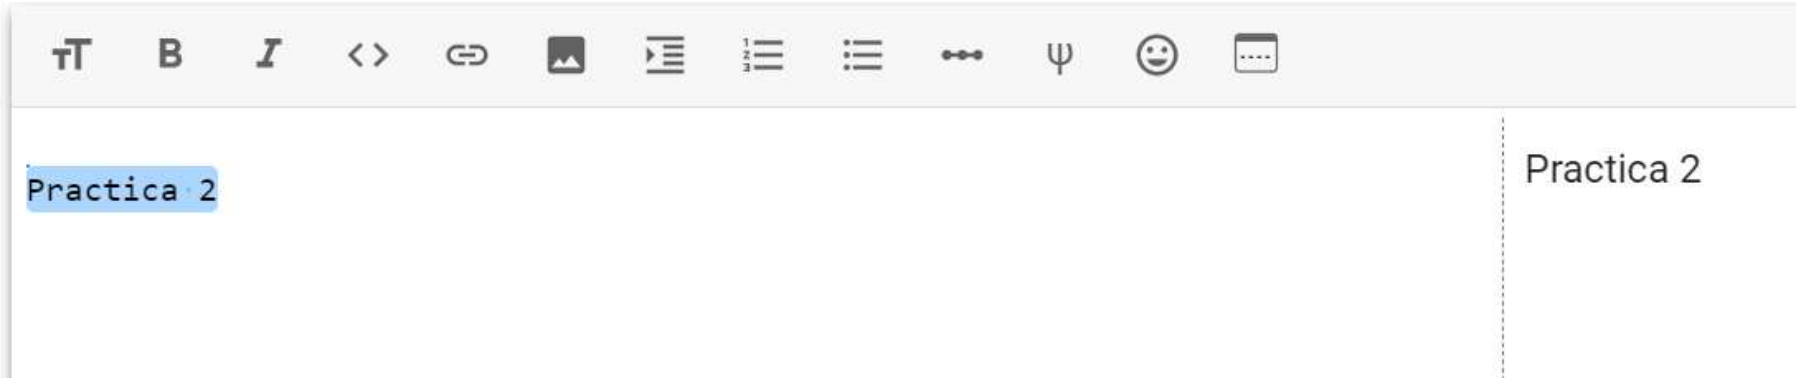
```
departamento_vs_educacion=pd.crosstab(index=original_df['Departamento'],columns=original_df['Campo_Educación'], margins=True)
departamento_vs_educacion
```

Campo_Educación	Ciencias	Humanidades	Mercadeo	Otra	Salud	Tecnicos	All
Departamento							
IyD	440	0	0	64	363	94	961
RH	16	27	0	3	13	4	63
Ventas	150	0	159	15	88	34	446
All	606	27	159	82	464	132	1470

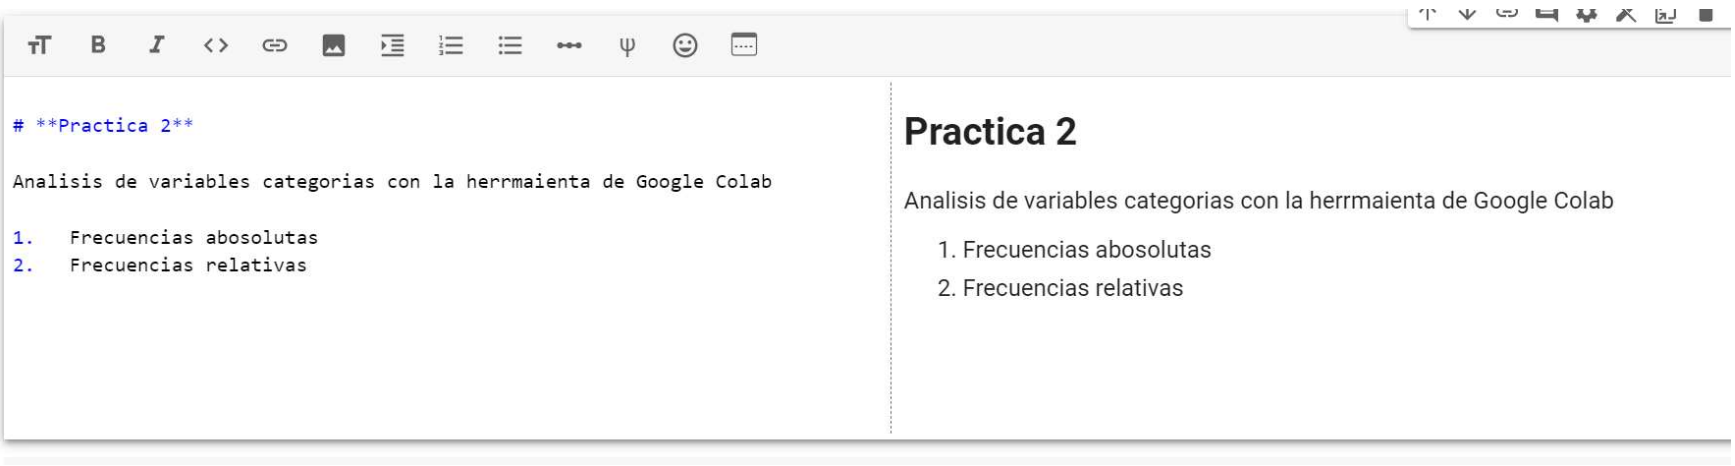
Practica

Opción texto

Se escribe, se selecciona la palabra y se aplica los formatos que se desea



Practica



```
# **Practica 2**

Analisis de variables categorias con la herrmaienta de Google Colab

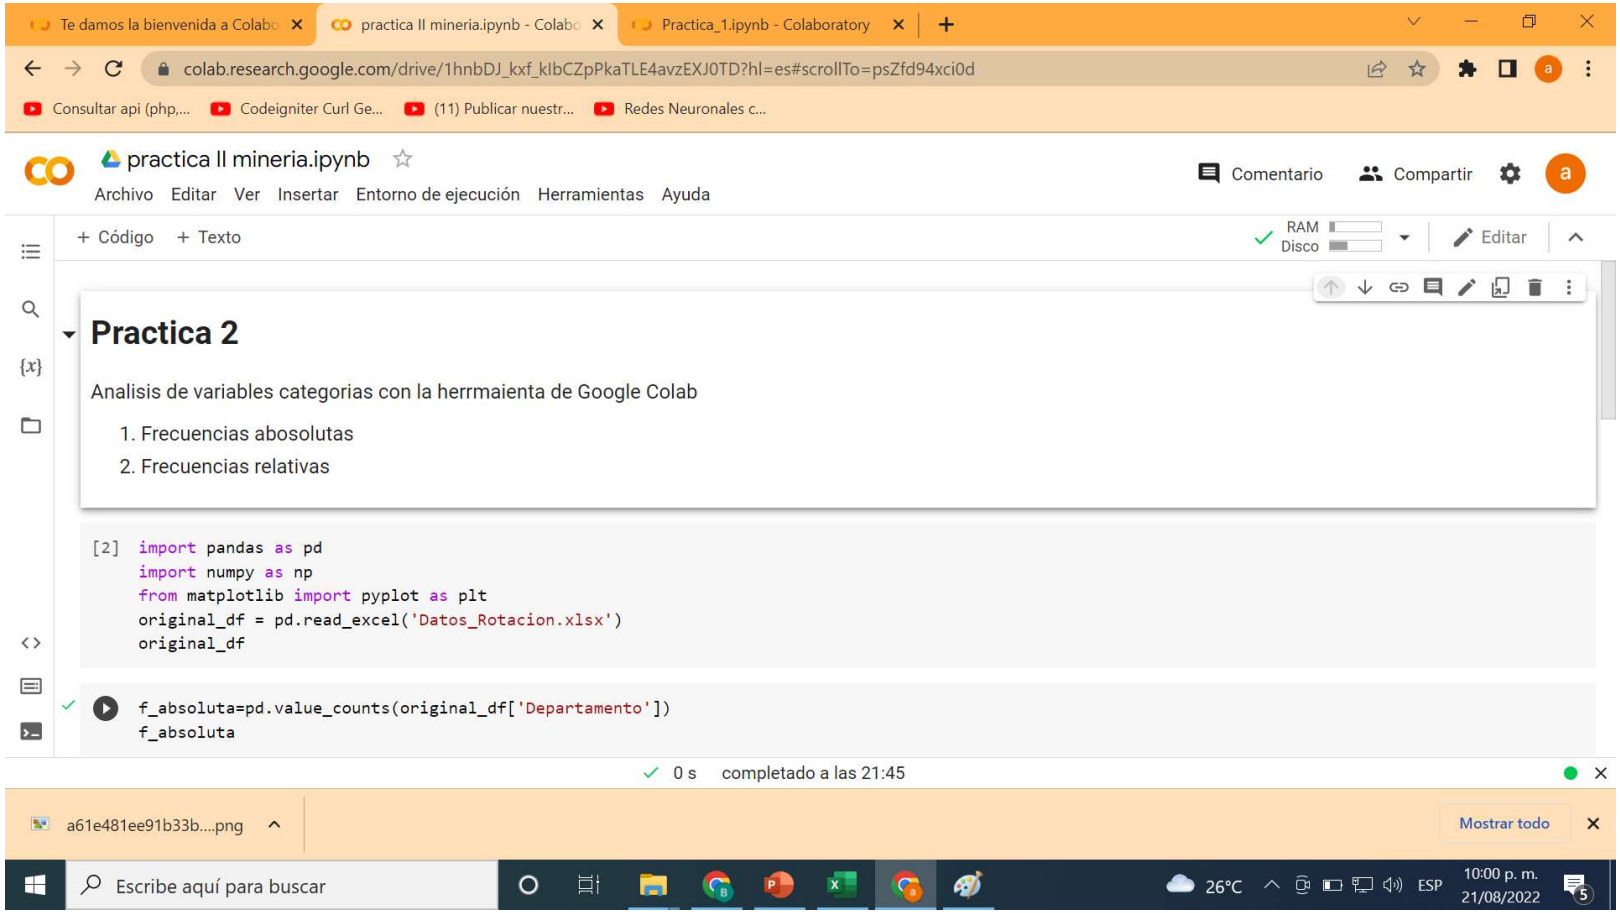
1.   Frecuencias abosolutas
2.   Frecuencias relativas
```

Practica 2

Analisis de variables categorias con la herrmaienta de Google Colab

1. Frecuencias abosolutas
2. Frecuencias relativas

Practica


Te damos la bienvenida a Colabo
practica II mineria.ipynb - Colabo
Practica_1.ipynb - Colaboratory
colab.research.google.com/drive/1hnbDJ_kxf_klbCZpPkaTLE4avzEXJ0TD?hl=es#scrollTo=psZfd94xci0d
Consultar api (php,...
Codeigniter Curl Ge...
(11) Publicar nuestr...
Redes Neuronales c...
practica II mineria.ipynb
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
Comentario
Compartir
+ Código + Texto
RAM
Disco
Editar
Practica 2
Analisis de variables categorias con la herrmaienta de Google Colab
1. Frecuencias abosolutas
2. Frecuencias relativas
[2] import pandas as pd
import numpy as np
from matplotlib import pyplot as plt
original_df = pd.read_excel('Datos_Rotacion.xlsx')
original_df
f_absoluta=pd.value_counts(original_df['Departamento'])
f_absoluta
0 s completado a las 21:45
a61e481ee91b33b....png
Mostrar todo
Escribe aquí para buscar
26°C
ESP
10:00 p. m.
21/08/2022

MINERÍA DE DATOS

Análisis Bivariado

Teniendo en cuenta la base de datos del tema anterior, se proceden a realizar las siguientes codificaciones.

MINERÍA DE DATOS

```
import pandas as pd
import numpy as np
from matplotlib import pyplot as plt
original_df = pd.read_excel('Datos_Rotacion.xlsx')
original_df
```

	Rotación	Edad	Viaje de Negocios	Departamento	Distancia_Casa	Educación	Campo_Educación	Satisfacción_Ambiental	Genero	Cargo	...	Horas_Extra	Porce
0	Si	41	Raramente	Ventas	1	2	Ciencias	2	F	Ejecutivo_Ventas	...	Si	
1	No	49	Frecuentemente	IyD	8	1	Ciencias	3	M	Investigador_Cientifico	...	No	
2	Si	37	Raramente	IyD	2	2	Otra	4	M	Tecnico_Laboratorio	...	Si	
3	No	33	Frecuentemente	IyD	3	4	Ciencias	4	F	Investigador_Cientifico	...	Si	
4	No	27	Raramente	IyD	2	1	Salud	1	M	Tecnico_Laboratorio	...	No	
...	...	...	...	...	...	...	...	...	...	...	...	...	
1465	No	36	Frecuentemente	IyD	23	2	Salud	3	M	Tecnico_Laboratorio	...	No	
1466	No	39	Raramente	IyD	6	1	Salud	4	M	Representante_Salud	...	No	
1467	No	27	Raramente	IyD	4	3	Ciencias	2	M	Director_Manofactura	...	Si	
1468	No	49	Frecuentemente	Ventas	2	3	Salud	4	M	Ejecutivo_Ventas	...	No	

Original_df.info()

```
original_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1470 entries, 0 to 1469
Data columns (total 24 columns):
 #   Column                      Non-Null Count  Dtype 
---  ------                      --------------  ----- 
 0   Rotación                    1470 non-null   object
 1   Edad                        1470 non-null   int64 
 2   Viaje de Negocios           1470 non-null   object
 3   Departamento                1470 non-null   object
 4   Distancia_Casa              1470 non-null   int64 
 5   Educación                   1470 non-null   int64 
 6   Campo_Educación             1470 non-null   object
 7   Satisfacción_Ambiental      1470 non-null   int64 
 8   Genero                      1470 non-null   object
 9   Cargo                       1470 non-null   object
 10  Satisfación_Laboral         1470 non-null   int64 
 11  Estado_Civil                1470 non-null   object
 12  Ingreso_Mensual             1470 non-null   int64 
 13  Trabajos_Anteriores         1470 non-null   int64 
 14  Horas_Extra                 1470 non-null   object
 15  Porcentaje_aumento_salarial 1470 non-null   int64 
 16  Rendimiento_Laboral         1470 non-null   int64 
 17  Años_Experiencia            1470 non-null   int64 
 18  Capacitaciones              1470 non-null   int64 
 19  Equilibrio_Trabajo_Vida     1470 non-null   int64 
 20  Antigüedad                  1470 non-null   int64 
 21  Antigüedad_Cargo            1470 non-null   int64 
 22  Años_ultima_promoción       1470 non-null   int64 
 23  Años_acargo_con_mismo_jefe  1470 non-null   int64 
dtypes: int64(16), object(8)
memory usage: 275.8+ KB
```

MINERÍA DE DATOS

Para el los siguientes códigos es necesario consultar los conceptos de

1,- función lambda.

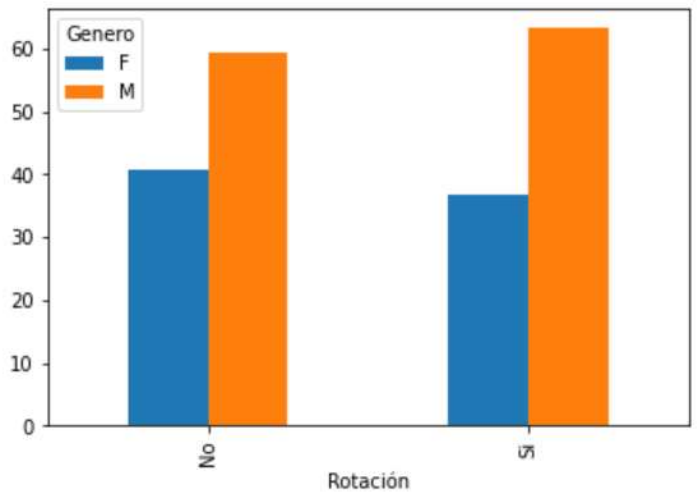
2,- axis en matplolib

3,-crosstab en Python

4,-figsize en matplotlib

MINERÍA DE DATOS

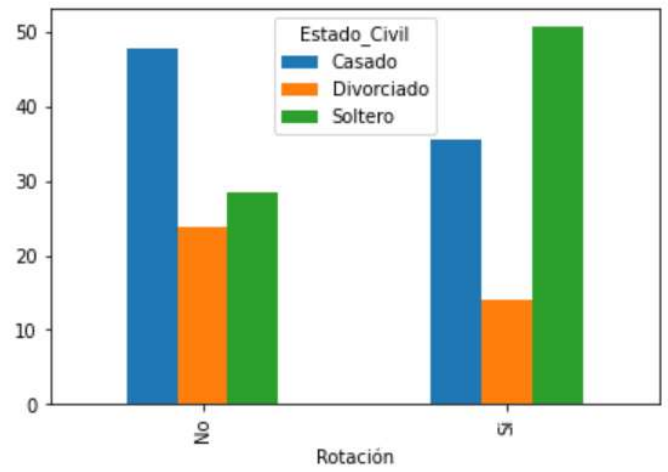
```
plot = pd.crosstab(index=original_df['Rotación'],columns=original_df['Genero']).apply(lambda r: r/r.sum() *100,axis=1).plot(kind='bar')
```



La grafica muestra el análisis bivariado de las variables rotación y genero. A partir del grafico se puede extraer conclusiones.

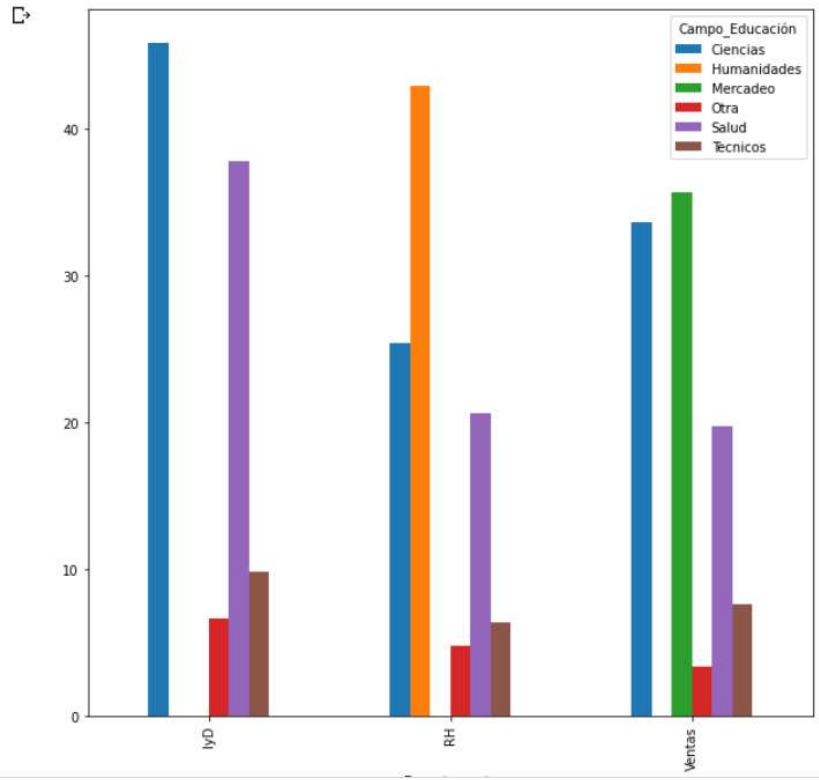
MINERÍA DE DATOS

```
plot = pd.crosstab(index=original_df['Rotación'],columns=original_df['Estado_Civil']).apply(lambda r: r/r.sum() *100,axis=1).plot(kind='bar')
```



La grafica muestra el análisis bivariado de las variables rotación y estado civil. A partir del grafico se puede extraer conclusiones.

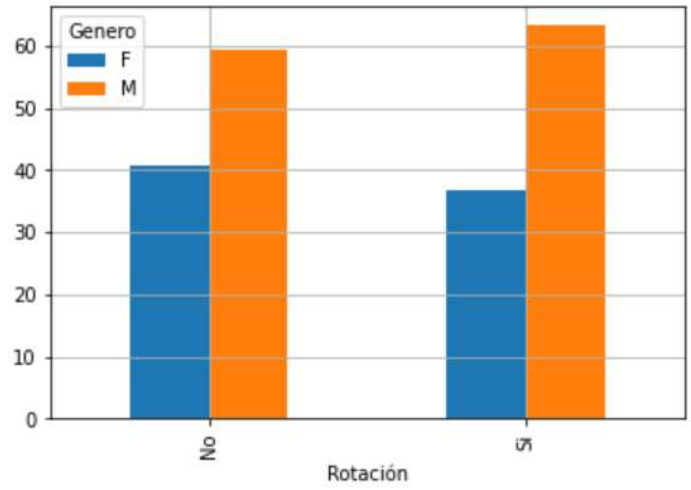
```
plot = pd.crosstab(index=original_df['Departamento'],columns=original_df['Campo_Educación']).apply(lambda r: r/r.sum() *100,axis=1,).plot(kind='bar',figsize=(10, 10))
```



La grafica muestra el análisis bivariado de las variables departamentos y campo_educacion. A partir del grafico se puede extraer conclusiones.

MINERÍA DE DATOS

```
plot = pd.crosstab(index=original_df['Rotación'],columns=original_df['Genero']).apply(lambda r: r/r.sum() *100,axis=1).plot(kind='bar')
plot.grid()
```



Para agregar líneas claras dentro del grafico se utiliza el método plot()

MINERÍA DE DATOS

Metodo unique(): El método Pandas Series unique() se utiliza cuando tratamos con una sola columna de un DataFrame y devuelve todos los elementos únicos de una columna. La salida final usando la función unique() es un array.

MINERÍA DE DATOS

```
[33] print(original_df['Departamento'].unique())
```

```
['Ventas' 'IyD' 'RH']
```

```
[34] print(original_df['Rotación'].unique())
```

```
['Si' 'No']
```

```
[35] print(original_df['Estado_Civil'].unique())
```

```
['Soltero' 'Casado' 'Divorciado']
```

```
print(original_df['Cargo'].unique())
```

```
['Ejecutivo_Ventas' 'Investigador_Cientifico' 'Tecnico_Laboratorio'
 'Director_Manofactura' 'Representante_Salud' 'Gerente'
 'Representante_Ventas' 'Director_Investigación' 'Recursos_Humanos']
```

Cambiar el tipo de dato

```
 1   Edad                        1470 non-null   int64
 2   Viaje de Negocios           1470 non-null   object
 3   Departamento                1470 non-null   object
 4   Distancia_Casa              1470 non-null   int64
 5   Educación                   1470 non-null   int64
 6   Campo_Educación             1470 non-null   object
 7   Satisfacción_Ambiental      1470 non-null   int64
 8   Genero                      1470 non-null   object
 9   Cargo                       1470 non-null   object
 10  Satisfación_Laboral         1470 non-null   int64
 11  Estado_Civil                1470 non-null   object
 12  Ingreso_Mensual             1470 non-null   int64
 13  Trabajos_Anteriores         1470 non-null   int64
 14  Horas_Extra                 1470 non-null   object
 15  Porcentaje_aumento_salarial 1470 non-null   int64
 16  Rendimiento_Laboral         1470 non-null   int64
 17  Años_Experiencia            1470 non-null   int64
 18  Capacitaciones              1470 non-null   int64
 19  Equilibrio_Trabajo_Vida     1470 non-null   int64
 20  Antigüedad                  1470 non-null   int64
 21  Antigüedad_Cargo            1470 non-null   int64
 22  Años_ultima_promoción       1470 non-null   int64
 23  Años_acargo_con_mismo_jefe  1470 non-null   int64
dtypes: int64(16), object(8)
memory usage: 275.8+ KB
```

MINERÍA DE DATOS

```
original_df[['Educación']] = original_df[['Educación']].astype(object)

original_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1470 entries, 0 to 1469
Data columns (total 24 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Rotación                  1470 non-null   object
 1   Edad                      1470 non-null   int64
 2   Viaje de Negocios         1470 non-null   object
 3   Departamento              1470 non-null   object
 4   Distancia_Casa            1470 non-null   int64
 5   Educación                 1470 non-null   object
 6   Campo_Educación           1470 non-null   object
 7   Satisfacción_Ambiental    1470 non-null   int64
 8   Genero                    1470 non-null   object
 9   Cargo                     1470 non-null   object
```

MINERÍA DE DATOS

Consultar como que es el diagrama de caja o diagrama de caja de bigotes.

Que son los cuartiles en el diagrama de caja de bigotes.

Como se interpreta un diagrama de cajas de bigotes. Consultar un ejemplo teórico.

Como se grafica un diagrama de caja de bigotes en Python.

BIBLIOGRAFIA

Pérez M(2015) Minería de datos a través de ejemplos Alfaomega.

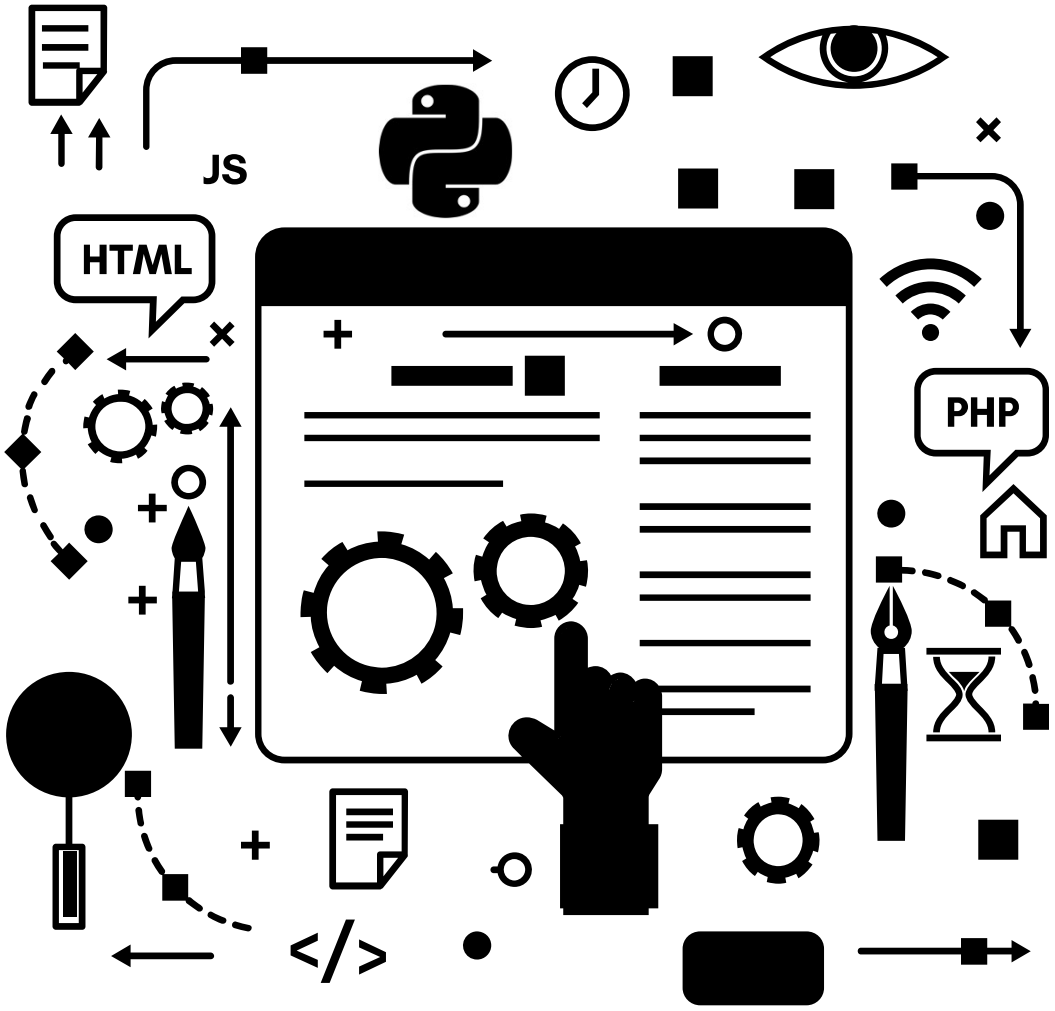
https://www.sas.com/es_co/insights/analytics/data-mining.html

https://www.ibm.com/docs/es/spss-modeler/SaaS?topic=preparation-data-overview

https://core.ac.uk/download/pdf/296346464.pdf

https://blog.powerdata.es/el-valor-de-la-gestion-de-datos/calidad-de-datos-en-mineria-de-datos-a-traves-del-preprocesamiento

https://www.codificandobits.com/blog/manejo-datos-faltantes/



Gracias.